

MiniMax-M2.5模型在不同芯片下的 benchmark基准测试报告

九章云极

测试环境

硬件规格

组件 \ 规格	英伟达	海光	昆仑芯	沐曦	备注
节点数量	1 台	1 台	1台	1 台	确认
芯片型号	H100	BW1000	P800 OAM	MetaX-C550	确认
芯片数量	8 张	8 张	8 张	8 张	确认
单卡算力 FP16/BF16	1979 TFLOPS (官方理论值)	待确认	待确认	待确认	⚠️ 待确认
单卡算力 FP32	67 TFLOPS (官方理论值)	待确认	待确认	待确认	⚠️ 待确认
单卡算力 FP64	34 TFLOPS (官方理论值)	待确认	待确认	待确认	⚠️ 待确认
单卡显存	80GB	64GB	96GB	64GB	确认
显存类型	HBM3	待确认	待确认	HBM2e	⚠️ 待确认
显存带宽	3.35 TB/s	待确认	待确认	待确认	⚠️ 待确认
单卡功耗	700 W	200 W	400 W	450 W	确认

组件 \ 规格	英伟达	海光	昆仑芯	沐曦	备注
卡间互联	NVLink 4.0	HSM	XPULink (XL) + PCIe Gen4 x16 (跨 NUMA 显示 SYS)	MetaXLink	确认
CPU	Intel(R) Xeon(R) Platinum 8468 (192核)	Hygon C86 (128核)	Intel Xeon Platinum 8563C (208核)	Intel(R) Xeon(R) Platinum 8480+ (224核)	确认
系统内存	2.0 TiB	503 GiB	2.0 TiB	1.8 TiB	确认
本地存储	894GB 系统盘 + 7TB*4 缓存盘 + 7TB 容器盘 + 25TB 扩展盘	437G系统盘 + 1.7TiB (G73M1T9R-C-GD308)	446.6G + NVMe 4 x 3.5T (Intel SSDPF2KX038T1)	446.6GB + NVMe 4 x 7T	确认

软件栈

组件\版本	英伟达	海光	昆仑芯	沐曦	备注
操作系统	Ubuntu 22.04.5 LTS	Ubuntu 22.04.5 LTS	Ubuntu 22.04.5 LTS	Ubuntu 20.04.1	沐曦
显卡驱动	570.133.20/580.126.09	6.3.22-V1.2.0	Kunlun / XPU Driver 5.0.21.26	Kernel Mode Driver Version: 3.6.11	沐曦
Toolkit	release 12.9	DTK-26.04-beta-0130-ubuntu20.04	XPU Container Runtime Hook version 1.0.5	MACA Version: 3.5.3.23	昆仑芯
Docker	-	28.0.4	28.4.0	28.1.1	昆仑芯
containerd	2.2.0	2.1.1	1.7.28	-	昆仑芯
Kubernetes	1.34.2	1.33	v1.28.2	-	昆仑芯
Device Plugin	0.14.5	v2.4.0	xpu-device-plugin v5.0.0-alpha.2	-	昆仑芯
多卡通信库	NCCL	DTK内置 RCCL	无单独查询版本	MCCLI	沐曦

部署方式

平台类别	部署方式
NVIDIA_H100	K8S部署
Hygon_BW1000	Docker容器部署
Kunlun_P800	Docker容器部署
MetaX_C550	Docker容器部署

模型配置信息

参数名称	NVIDIA_H100	Hygon_BW1000
model_name	MiniMax-M2.5	MiniMax-M2.5-bf16
quantization_config	FP8	bf16
model_size	215G	427G
max_position_embeddings	196608	196608
temperature	1.0	N/A
top_k	40	N/A
top_p	0.95	N/A
transformers_version	4.46.1	4.46.1
vllm_version	0.20.0	0.11.0+das.opt1.rc2.dtk2604.20260128
sglang_version	-	-
python_version	3.12.3	3.10.12



推理框架主要启动参数

参数名称	NVIDIA_H100	Hygon_BW1000	Hygon_BW1000	Kunlun_P80
Model Name	MiniMax-M2.5	MiniMax-M2.5-bf16	MiniMax-M2.5-W8A8	MiniMax-M2
Max Model Len	196608	196608	196608	196608
Max Num Seqs	64	64	64	64
Max Num Batched Tokens	8192	default	default	8192
Block Size	default	default	default	128
Gpu Memory Utilization	0.85	0.9	0.9	0.95
Compilation Config	-	-	-	{"splitting_o "vllm.unifiec "vllm.unifiec "vllm.mamb "vllm.mamb "vllm.short_ "vllm.linear_ "vllm.plamo "vllm.gdn_at "vllm.sparse "vllm.sparse
Dtype	default	bfloat16	bfloat16	auto
Dp	1	1	1	1
Tp	8	8	8	8
Pp	1	1	1	1
Reasoning Parser	minimax_m2	minimax_m2	minimax_m2	minimax_m2
Tool Call Parser	minimax_m2	minimax_m2	minimax_m2	minimax_m2
Enable Auto Tool Choice	True	True	True	True

参数名称	NVIDIA_H100	Hygon_BW1000	Hygon_BW1000	Kunlun_P800
Enable Export Parallel	True	True	True	False

各芯片平台的Minimax_M2.5模型的详细部署脚本参见本文档的《附录一》


测试场景一：短上下文长度性能比对

测试概览


项目	配置	备注
数据集	random	
并发数	1, 64	
总请求数	320	
请求输入上下文长度	10240 (10k)	
请求输出上下文长度	256 (0.25k)	
被测芯片和模型	NVIDIA_H100: MiniMax-M2.5-FP8 Hygon_BW1000: MiniMax-M2.5-bf16 Hygon_BW1000: MiniMax-M2.5-W8A8 Kunlun_P800: MiniMax-M2.5-W8A8-INT8-Dynamic inspur_MetaX_C550: MiniMax-M2.5-W8A8	

芯片性能对比柱状图

1并发



64并发



各芯片平台不同并发级别各指标性能对比详情

请求吞吐量（Request throughput (req/s)）

并发数	NVIDIA_H100(基准)	Hygon_BW1000_bf16	相对基准	Hygon_BW1000_W8A8
1	0.45	0.10	-77.8%	0.21
64	3.66	0.16	-95.6%	0.82

输出token吞吐量（Output token throughput (tok/s)）

并发数	NVIDIA_H100(基准)	Hygon_BW1000_bf16	相对基准	Hygon_BW1000_W8A8
1	115.31	24.66	-78.6%	54.28
64	937.16	41.54	-95.6%	210.25

总token吞吐量（Total token throughput (tok/s)）

并发数	NVIDIA_H100(基准)	Hygon_BW1000_bf16	相对基准	Hygon_BW1000_W8A8
1	4745.14	1010.87	-78.7%	2225.40
64	38566.45	1702.94	-95.6%	8620.30

首token延迟（P99 TTFT (ms)）

并发数	NVIDIA_H100(基准)	Hygon_BW1000_bf16	相对基准	Hygon_BW1000_W8A8
1	286.01	5130.17	+1693.7%	1168.49
64	12557.76	382166.79	+2943.3%	63531.55

每token生成时间（P99 TPOT (ms)）

并发数	NVIDIA_H100(基准)	Hygon_BW1000_bf16	相对基准	Hygon_BW1000_W8A8
1	7.68	21.07	+174.3%	14.16
64	66.03	598.42	+806.3%	300.74

token间延迟（P99 ITL (ms)）

并发数	NVIDIA_H100(基准)	Hygon_BW1000_bf16	相对基准	Hygon_BW1000_W8A
1	8.57	32.03	+273.7%	20.17
64	170.95	160.09	-6.4%	64.72




测试场景二： 超长上下文长度性能比对

 测试概览


项目	配置	备注
数据集	random	
并发数	1, 10	
总请求数	100	
请求输入上下文长度	194560（190k）	
请求输出上下文长度	1024（1k）	
被测芯片	NVIDIA_H100：MiniMax-M2.5-FP8 Hygon_BW1000: MiniMax-M2.5-bf16 Hygon_BW1000: MiniMax-M2.5-W8A8 Kunlun_P800: MiniMax-M2.5-W8A8-INT8-Dynamic inspur_MetaX_C550: MiniMax-M2.5-W8A8	

 芯片性能对比柱状图

1并发



10并发



各芯片平台不同并发级别各指标性能对比详情

请求吞吐量（Request throughput (req/s)）

并发数	NVIDIA_H100(基准)	Hygon_BW1000_bf16	相对基准	Hygon_BW1000_W8A8
1	0.05	0.01	-80.0%	0.01
10	0.07	0.01	-85.7%	0.01

输出token吞吐量（Output token throughput (tok/s)）

并发数	NVIDIA_H100(基准)	Hygon_BW1000_bf16	相对基准	Hygon_BW1000_W8A8
1	46.70	7.21	-84.6%	15.31
10	75.37	5.74	-92.4%	15.00

总token吞吐量（Total token throughput (tok/s)）

并发数	NVIDIA_H100(基准)	Hygon_BW1000_bf16	相对基准	Hygon_BW1000_W8A8
1	8921.40	1376.58	-84.6%	2924.75
10	14398.41	1096.76	-92.4%	2865.09

首token延迟（P99 TTFT (ms)）

并发数	NVIDIA_H100(基准)	Hygon_BW1000_bf16	相对基准	Hygon_BW1000_W8A8
1	10539.10	114142.41	+983.0%	44121.71
10	108342.29	1781035.71	+1543.9%	474297.92

每token生成时间（P99 TPOT (ms)）

并发数	NVIDIA_H100(基准)	Hygon_BW1000_bf16	相对基准	Hygon_BW1000_W8A8
1	11.39	29.56	+159.5%	22.97
10	69.61	45.57	-34.5%	279.90

token间延迟（P99 ITL (ms)）

并发数	NVIDIA_H100(基准)	Hygon_BW1000_bf16	相对基准	Hygon_BW1000_W8A
1	22.97	53.91	+134.7%	32.12
10	639.97	55.14	-91.4%	4012.34

vllm bench serve性能测试脚本见本报告《附录二》

附录一

NVIDIA_H100平台Minimax-M2.5模型部署

```
export TORCH_CUDA_ARCH_LIST="9.0+PTX"
export OMP_NUM_THREADS=8

export PYTHONHASHSEED=0
export PYTHONUNBUFFERED=1
export VLLM_NO_USAGE_STATS=1
export VLLM_LOGGING_LEVEL=INFO
export NCCL_IB_DISABLE=0
export NCCL_IB_HCA=ib7s400p0,ib7s400p1
export NCCL_SOCKET_IFNAME=eth0 #bond0
export GLOO_SOCKET_IFNAME=eth0 #bond0

MODEL_PATH=/userdata/llms/MiniMax/MiniMax-M2.5
MODEL_ID="minimax-m2.5 minmax-m25"
API_KEY=abc123
#MAX_LEN=$(( 1024 * 196 ))
MAX_LEN=196608
MAX_SEQ=64
MAX_BS=8192

DP=1
TP=8
PP=1

CG="$(seq -s ' ' 1 15) $(seq -s ' ' 16 4 31) $(seq -s ' ' 32 8 256)"
TAG=$(gen_ofile)
log_file=$TAG-tp$TP-pp$PP.log
echo log_file: $log_file

export LMCACHE_USE_EXPERIMENTAL=True
export LMCACHE_CONFIG_FILE="/userdata/bin/lmcache_mm25.yaml"
```

```
set -x

vllm serve $MODEL_PATH \
    --max-model-len $MAX_LEN \
    --max-num-seqs $MAX_SEQ \
    --max-num-batched-tokens $MAX_BS \
    --trust-remote-code \
    --gpu-memory-utilization 0.85 \
    --disable-log-requests \
    --disable-uvicorn-access-log \
    --port 8080 \
    --host 0.0.0.0 \
    --served-model-name $MODEL_ID \
    -dp $DP -tp $TP -pp $PP \
    --enable-expert-parallel \
    --enable-auto-tool-choice --tool-call-parser minimax_m2 --
reasoning-parser minimax_m2 \
    --cudagraph-capture-sizes $CG \
    2>&1 | tee -a $log_file
```

Hygon_BW1000平台Minimax-M2.5-bf16模型部署

```
vllm serve /data/models/MiniMax-M2.5-bf16 \
    -tp 8 \
    --trust-remote-code \
    --disable-log-requests \
    --port 8080 \
    --max-num-seqs 64 \
    --max-model-len 196608 \
    --gpu-memory-utilization 0.9 \
    --dtype bfloat16 \
    --served-model-name minimax-m2.5 \
    --enable-expert-parallel \
    --enable-auto-tool-choice \
    --tool-call-parser minimax_m2
```

Hygon_BW1000平台Minimax-M2.5-W8A8模型部署

```
vllm serve /data/models/MiniMax-M2.5-W8A8 \
  -tp 8 \
  --trust-remote-code \
  --disable-log-requests \
  --port 8080 \
  --max-num-seqs 64 \
  --max-model-len 196608 \
  --gpu-memory-utilization 0.9 \
  --dtype bfloat16 \
  --served-model-name minimax-m2.5 \
  -cc '{"pass_config": {"fuse_act_quant": false}}' \
  --enable-auto-tool-choice \
  --tool-call-parser minimax_m2
```

Kunlun_P800平台MiniMax-M2.5-W8A8-INT8-Dynamic模型部署

```
source /root/miniconda/bin/activate python310_torch25_cuda

unset XPU_DUMMY_EVENT
export XPU_VISIBLE_DEVICES=0,1,2,3,4,5,6,7
export XPU_USE_FAST_SWIGLU=1
export XFT_USE_FAST_SWIGLU=1
export XMLIR_CUDNN_ENABLED=1
export XPU_USE_DEFAULT_CTX=1
export XMLIR_FORCE_USE_XPU_GRAPH=1
export XMLIR_ENABLE MOCK_TORCH_COMPILE=false
export VLLM_USE_V1=1
export USE_ORI_ROPE=1
export VLLM_USE_TRITON_FLASH_ATTN=
export VLLM_ATTENTION_BACKEND=FLASH_ATTN
export VLLM_KUNLUN_DISABLE_TRITON=1
export XMLIR_MATMUL_FAST_MODE=1

python -m vllm.entrypoints.openai.api_server \
  --host 0.0.0.0 \
  --port 8080 \
  --model /data/MiniMax-M2.5-W8A8-INT8-Dynamic \
  --served-model-name minimax-m2.5 \
  --gpu-memory-utilization 0.95 \
  --trust-remote-code \
  --max-model-len 196608 \
  --tensor-parallel-size 8 \
  --dtype auto \
  --max_num_seqs 64 \
  --max_num_batched_tokens 8192 \
  --block-size 128 \
  --distributed-executor-backend mp \
```

```

--enable-auto-tool-choice \
--tool-call-parser minimax_m2 \
--reasoning-parser minimax_m2 \
--compilation-config '{"splitting_ops":
["vllm.unified_attention","vllm.unified_attention_with_output","vllm.unifie
d_attention_with_output_kunlun","vllm.mamba_mixer2","vllm.mamba_mixer","vll
m.short_conv","vllm.linear_attention","vllm.plamo2_mamba_mixer","vllm.gdn_a
ttention","vllm.sparse_attn_indexer","vllm.sparse_attn_indexer_vllm_kunlun"
]}'

```

MetaX_C550平台Minimax-M2.5-W8A8模型部署

```

#!/bin/bash
# 10.130.70.2
# 10.130.70.1

mx-smi -r -i all

export
PYTORCH_CUDA_ALLOC_CONF=expandable_segments:True,max_split_size_mb:128
export GLOO_SOCKET_IFNAME=ens12f0
export MCCL_SOCKET_IFNAME=ens12f0
export MCCL_IB_HCA=m1x5_0,m1x5_1,m1x5_2,m1x5_3,m1x5_4,m1x5_5,m1x5_6,m1x5_7
export TRITON_ENABLE_MACAP_OPT_MOVE_DOT_OPERANDS_OUT_LOOP=1
export TRITON_ENABLE_MACAP_CHAIN_DOT_OPT=1

# 通用环境变量
export MACA_SMALL_PAGESIZE_ENABLE=1
export TRITON_ENABLE_MACA_OPT_MOVE_DOT_OPERANDS_OUT_LOOP=1
export TRITON_ENABLE_MACA_CHAIN_DOT_OPT=1

# BF16、W8A8-TP2DP8/TP4DP4
export PYTORCH_ENABLE_PG_HIGH_PRIORITY_STREAM=1
export MACA_QUEUE_SCHEDULE_POLICY=1
export MACA_DIRECT_DISPATCH=1

# 启用Flash_mla的优化（必须按照4.2.1操作更新flashmla）
export MX_ENABLE_FLASH_MLA_OPT=1

# add from 0.5.9
export TORCH_CUDA_ARCH_LIST="8.0 8.6+PTX"

service ssh restart

model_name=MiniMax-M2.5-W8A8
model_path="/data/data_shared/${model_name}"
log_file=./log-sglang-server-master-${model_name}.log

python3 -m sglang.launch_server \
    --model-path $model_path \

```



```
--trust-remote-code \  
--attention-backend flashinfer \  
--quantization w8a8_int8 \  
--served-model-name minimax-m2.5 \  
--tp-size 8 \  
--context-length 196608 \  
--max-running-requests 64 \  
--dist-init-addr 10.130.70.1:36555 \  
--host 0.0.0.0 \  
--port 8000 \  
--nnodes 1 \  
--node-rank 0 \  
--disable-radix-cach \  
--disable-chunked-prefix-cache \  
--tool-call-parser minimax-m2 \  
--reasoning-parser minimax-append-think \  
--mem-fraction-static 0.9 2>&1 | tee -a ${log_file}
```

附录二 性能测试脚本

vllm bench serve测试脚本

```
vllm bench serve  
--backend openai-chat  
--endpoint /v1/chat/completions  
--dataset-name random  
--random-input-len 10240  
--random-output-len 256  
--model ${MODEL_PATH}  
--trust-remote-code  
--base-url ${BASE_URL}  
--num-prompts 320  
--max-concurrency 1  
--temperature 0.7  
--seed 123  
--metric_percentiles 95,99  
--served-model-name ${MODEL}  
--ready-check-timeout-sec 30
```

sglang bench serve测试脚本

```
python3 -m sglang.bench_serving \  
  --backend sglang \  
  --dataset-name random \  
  --dataset-path /home/workspace/ShareGPT_v3_unfiltered_cleaned_split.json \  
  \  
  --random-range-ratio 1.0 \  
  --host 0.0.0.0 \  
  --port 8000 \  
  --random-input-len 10240 \  
  --random-output-len 256 \  
  --max-concurrency 1 \  
  --num-prompt 320
```

报告生成时间: 2026-06-09

九章云极