

MiniMax-M2.5模型在不同芯片下的benchmark基准测试报告

测试日期： 2026-05-25

测试场景

在固定请求数，输入上下文和输出上下文长度下，使用vllm bench serve工具对并发数逐级增加场景的性能基准验证。并对比同一模型在不同芯片环境上的性能指标。

主要采集指标：

指标	单位	含义
TTFT	ms	Time To First Token，首 token 延迟
TPOT	ms/token	Time Per Output Token，每 token 生成时间
Throughput	tokens/s	系统总吞吐
QPS	requests/s	请求吞吐
P50/P95/P99 Latency	ms	延迟分位数



测试概览

项目	配置	备注
数据集	random	
并发数	1, 2, 4, 8, 10, 16, 32, 64, 80, 128	
总请求数	320	
请求输入上下文长度	10240 (10k)	
请求输出上下文长度	256 (0.25k)	
被测芯片	NVIDIA_H100, Kunlun_P800	
被测模型	MiniMax-M2.5	

 芯片和模型配置信息

参数名称	NVIDIA_H100	Kunlun_P800
max_position_embeddings	196608	196608
model_name	MiniMax-M2.5	MiniMax-M2.5-W8A8-INT8-Dynamic
model_size	215G	215G
python_version	3.12.3	3.10.15
quantization_config	FP8	int-8
temperature	1.0	1.0
top_k	40	40
top_p	0.95	0.95
transformers_version	4.46.1	4.46.1
vllm_version	0.20.0	0.11.0


⚙️ vLLM启动配置信息

参数名称	NVIDIA_H100	Kunlun_P800
Block Size	default	128
Compilation Config	N/A	{ "splitting_ops":["vllm.unified_attention", "vllm.unified_attention_with_output", "vllm.unified_attention_with_output_kunlun", "vllm.mamba_mixer2", "vllm.mamba_mixer", "vllm.short_conv", "vllm.linear_attention", "vllm.plamo2_mamba_mixer", "vllm.gdn_attention", "vllm.sparse_attn_indexer", "vllm.sparse_attn_indexer_vllm_kunlun"] }
Dp	1	1
Dtype	default	auto
Enable Auto Tool Choice	True	True
Enable Export Parallel	True	False
Gpu Memory Utilization	0.85	0.95
Max Model Len	196608	196608
Max Num Batched Tokens	8192	8192
Max Num Seqs	64	64
Model Name	MiniMax-M2.5	MiniMax-M2.5-W8A8-INT8-Dynamic
Pp	1	1
Reasoning Parser	minimax_m2	minimax_m2 (不生效)
Tool Call Parser	minimax_m2	minimax_m2
Tp	8	8


- **NVIDIA_H100:** 英伟达H100标准配置
- **Kunlun_P800:** 昆仑芯不启用专家并行避免通信问题

📊 芯片性能对比柱状图


1并发




2并发




4并发




8并发




10并发




16并发




32并发




64并发




80并发



128并发



性能趋势对比图 (所有芯片)





各指标随并发级别性能对比详情

请求吞吐量（Request throughput (req/s)）

并发数	NVIDIA_H100	Kunlun_P800	差值	百分比
1	0.45	0.15	-0.30	-66.7%
2	0.78	0.26	-0.52	-66.7%
4	1.26	0.41	-0.85	-67.5%
8	1.82	0.57	-1.25	-68.7%
10	2.09	0.61	-1.48	-70.8%
16	2.51	0.74	-1.77	-70.5%
32	3.12	0.91	-2.21	-70.8%
64	3.66	1.02	-2.64	-72.1%
80	3.67	1.02	-2.65	-72.2%
128	3.66	1.02	-2.64	-72.1%

输出token吞吐量（Output token throughput (tok/s)）

并发数	NVIDIA_H100	Kunlun_P800	差值	百分比
1	115.31	37.20	-78.11	-67.7%
2	199.70	64.02	-135.68	-67.9%
4	323.45	102.96	-220.49	-68.2%
8	465.99	141.69	-324.30	-69.6%
10	534.52	152.16	-382.36	-71.5%
16	643.80	181.52	-462.28	-71.8%
32	797.81	223.77	-574.04	-72.0%
64	937.16	253.92	-683.24	-72.9%
80	938.91	255.42	-683.49	-72.8%
128	937.61	254.79	-682.82	-72.8%

总token吞吐量 (Total token throughput (tok/s))

并发数	NVIDIA_H100	Kunlun_P800	差值	百分比
1	4745.14	1585.87	-3159.27	-66.6%
2	8217.92	2705.12	-5512.80	-67.1%
4	13310.92	4342.80	-8968.12	-67.4%
8	19176.39	5980.27	-13196.12	-68.8%
10	21996.95	6448.31	-15548.64	-70.7%
16	26494.03	7730.83	-18763.20	-70.8%
32	32831.81	9513.02	-23318.79	-71.0%
64	38566.45	10682.97	-27883.48	-72.3%
80	38638.21	10653.29	-27984.92	-72.4%
128	38585.00	10666.52	-27918.48	-72.4%

首token延迟 (P99 TTFT (ms))

并发数	NVIDIA_H100	Kunlun_P800	差值	百分比
1	286.01	921.76	+635.75	+222.3%
2	466.40	1591.52	+1125.12	+241.2%
4	826.89	2240.56	+1413.67	+171.0%
8	1364.44	3847.84	+2483.40	+182.0%
10	1534.23	5143.91	+3609.68	+235.3%
16	2630.84	9917.09	+7286.25	+277.0%
32	6556.86	22359.61	+15802.75	+241.0%
64	12557.76	47912.19	+35354.43	+281.5%
80	19679.20	71633.46	+51954.26	+264.0%
128	29645.32	110786.32	+81141.00	+273.7%

每token生成时间（P99 TPOT (ms)）

并发数	NVIDIA_H100	Kunlun_P800	差值	百分比
1	7.68	23.38	+15.70	+204.4%
2	9.05	30.53	+21.48	+237.3%
4	11.41	40.56	+29.15	+255.5%
8	35.95	59.82	+23.87	+66.4%
10	17.75	68.00	+50.25	+283.1%
16	23.92	92.41	+68.49	+286.3%
32	38.79	163.15	+124.36	+320.6%
64	66.03	271.54	+205.51	+311.2%
80	66.45	255.96	+189.51	+285.2%
128	66.52	325.18	+258.66	+388.8%

token间延迟（P99 ITL (ms)）

并发数	NVIDIA_H100	Kunlun_P800	差值	百分比
1	8.57	24.07	+15.50	+180.9%
2	16.54	58.36	+41.82	+252.8%
4	18.61	586.65	+568.04	+3052.3%
8	152.68	593.49	+440.81	+288.7%
10	155.84	596.54	+440.70	+282.8%
16	161.83	602.60	+440.77	+272.4%
32	166.38	619.41	+453.03	+272.3%
64	170.95	635.84	+464.89	+271.9%
80	171.22	638.32	+467.10	+272.8%
128	170.62	635.16	+464.54	+272.3%

 各并发级别性能对比详情

1 并发

服务基准结果

指标	NVIDIA_H100	Kunlun_P800
成功请求数	320	320
失败请求数	0	0
测试持续时间 (s)	710.45	2115.85
总输入 tokens	3289280	3276748
总生成 tokens	81920	78707
请求吞吐量 (req/s)	0.45 ★	0.15
输出 token 吞吐量 (tok/s)	115.31 ★	37.20
峰值输出 token 吞吐量 (tok/s)	132.00 ★	44.00
峰值并发请求数	2.00	2.00
总 token 吞吐量 (tok/s)	4745.14 ★	1585.87

首Token延迟 (TTFT)

指标	NVIDIA_H100	Kunlun_P800
平均 TTFT (ms)	264.19 ★	898.33
中位 TTFT (ms)	264.45 ★	901.43
P95 TTFT (ms)	275.76 ★	915.80
P99 TTFT (ms)	286.01 ★	921.76

每Token生成时间 (TPOT)

指标	NVIDIA_H100	Kunlun_P800
平均 TPOT (ms)	7.67 ★	23.32
中位 TPOT (ms)	7.67 ★	23.32
P95 TPOT (ms)	7.68 ★	23.36
P99 TPOT (ms)	7.68 ★	23.38

Token间延迟 (ITL)

指标	NVIDIA_H100	Kunlun_P800
平均 ITL (ms)	7.70 ★	23.26
中位 ITL (ms)	7.69 ★	23.31
P95 ITL (ms)	7.83 ★	23.49
P99 ITL (ms)	8.57 ★	24.07

2 并发

服务基准结果

指标	NVIDIA_H100	Kunlun_P800
成功请求数	320	320
失败请求数	0	0
测试持续时间 (s)	410.23	1240.67
总输入 tokens	3289280	3276748
总生成 tokens	81920	79423
请求吞吐量 (req/s)	0.78 ★	0.26
输出 token 吞吐量 (tok/s)	199.70 ★	64.02
峰值输出 token 吞吐量 (tok/s)	244.00 ★	83.00
峰值并发请求数	4.00	4.00
总 token 吞吐量 (tok/s)	8217.92 ★	2705.12

首Token延迟 (TTFT)

指标	NVIDIA_H100	Kunlun_P800
平均 TTFT (ms)	360.79 ★	978.55
中位 TTFT (ms)	284.36 ★	923.32
P95 TTFT (ms)	463.55 ★	1575.42
P99 TTFT (ms)	466.40 ★	1591.52

每Token生成时间 (TPOT)

指标	NVIDIA_H100	Kunlun_P800
平均 TPOT (ms)	8.64 ★	27.38
中位 TPOT (ms)	8.65 ★	27.56
P95 TPOT (ms)	9.04 ★	28.88
P99 TPOT (ms)	9.05 ★	30.53

Token间延迟 (ITL)

指标	NVIDIA_H100	Kunlun_P800
平均 ITL (ms)	8.68 ★	27.40
中位 ITL (ms)	8.28 ★	24.60
P95 ITL (ms)	8.46 ★	24.82
P99 ITL (ms)	16.54 ★	58.36

4 并发

服务基准结果

指标	NVIDIA_H100	Kunlun_P800
成功请求数	320	320
失败请求数	0	0
测试持续时间 (s)	253.27	772.85
总输入 tokens	3289280	3276748
总生成 tokens	81920	79574
请求吞吐量 (req/s)	1.26 ★	0.41
输出 token 吞吐量 (tok/s)	323.45 ★	102.96
峰值输出 token 吞吐量 (tok/s)	436.00 ★	157.00
峰值并发请求数	8.00	8.00
总 token 吞吐量 (tok/s)	13310.92 ★	4342.80

首Token延迟 (TTFT)

指标	NVIDIA_H100	Kunlun_P800
平均 TTFT (ms)	584.15 ★	1017.52
中位 TTFT (ms)	582.44 ★	915.96
P95 TTFT (ms)	821.10 ★	1618.56
P99 TTFT (ms)	826.89 ★	2240.56

每Token生成时间 (TPOT)

指标	NVIDIA_H100	Kunlun_P800
平均 TPOT (ms)	10.12 ★	34.77
中位 TPOT (ms)	10.02 ★	34.97
P95 TPOT (ms)	11.39 ★	37.89
P99 TPOT (ms)	11.41 ★	40.56

Token间延迟 (ITL)

指标	NVIDIA_H100	Kunlun_P800
平均 ITL (ms)	10.20 ★	35.04
中位 ITL (ms)	9.24 ★	26.08
P95 ITL (ms)	9.57 ★	27.03
P99 ITL (ms)	18.61 ★	586.65

8 并发

服务基准结果

指标	NVIDIA_H100	Kunlun_P800
成功请求数	320	320
失败请求数	0	0
测试持续时间 (s)	175.80	561.22
总输入 tokens	3289280	3276748
总生成 tokens	81920	79521
请求吞吐量 (req/s)	1.82 ★	0.57
输出 token 吞吐量 (tok/s)	465.99 ★	141.69
峰值输出 token 吞吐量 (tok/s)	760.00 ★	257.00
峰值并发请求数	16.00	11.00
总 token 吞吐量 (tok/s)	19176.39 ★	5980.27

首Token延迟 (TTFT)

指标	NVIDIA_H100	Kunlun_P800
平均 TTFT (ms)	931.63 ★	1159.47
中位 TTFT (ms)	935.84 ★	936.85
P95 TTFT (ms)	1245.61 ★	1649.19
P99 TTFT (ms)	1364.44 ★	3847.84

每Token生成时间 (TPOT)

指标	NVIDIA_H100	Kunlun_P800
平均 TPOT (ms)	13.58 ★	51.78
中位 TPOT (ms)	13.24 ★	52.18
P95 TPOT (ms)	15.59 ★	55.27
P99 TPOT (ms)	35.95 ★	59.82

Token间延迟 (ITL)

指标	NVIDIA_H100	Kunlun_P800
平均 ITL (ms)	13.66 ★	51.62
中位 ITL (ms)	10.60 ★	31.87
P95 ITL (ms)	11.15 ★	214.19
P99 ITL (ms)	152.68 ★	593.49

10 并发

服务基准结果

指标	NVIDIA_H100	Kunlun_P800
成功请求数	320	320
失败请求数	0	0
测试持续时间 (s)	153.26	520.44
总输入 tokens	3289280	3276748
总生成 tokens	81920	79192
请求吞吐量 (req/s)	2.09 ★	0.61
输出 token 吞吐量 (tok/s)	534.52 ★	152.16
峰值输出 token 吞吐量 (tok/s)	900.00 ★	291.00
峰值并发请求数	19.00	14.00
总 token 吞吐量 (tok/s)	21996.95 ★	6448.31

首Token延迟 (TTFT)

指标	NVIDIA_H100	Kunlun_P800
平均 TTFT (ms)	827.89 ★	1456.60
中位 TTFT (ms)	875.37 ★	1282.49
P95 TTFT (ms)	1309.06 ★	3221.43
P99 TTFT (ms)	1534.23 ★	5143.91

每Token生成时间 (TPOT)

指标	NVIDIA_H100	Kunlun_P800
平均 TPOT (ms)	15.52 ★	59.81
中位 TPOT (ms)	15.31 ★	60.91
P95 TPOT (ms)	17.71 ★	65.57
P99 TPOT (ms)	17.75 ★	68.00

Token间延迟 (ITL)

指标	NVIDIA_H100	Kunlun_P800
平均 ITL (ms)	15.60 ★	59.57
中位 ITL (ms)	11.23 ★	35.48
P95 ITL (ms)	12.43 ★	217.00
P99 ITL (ms)	155.84 ★	596.54

16 并发

服务基准结果

指标	NVIDIA_H100	Kunlun_P800
成功请求数	320	320
失败请求数	0	0
测试持续时间 (s)	127.24	434.05
总输入 tokens	3289280	3276748
总生成 tokens	81920	78788
请求吞吐量 (req/s)	2.51 ★	0.74
输出 token 吞吐量 (tok/s)	643.80 ★	181.52
峰值输出 token 吞吐量 (tok/s)	1248.00 ★	417.00
峰值并发请求数	26.00	20.00
总 token 吞吐量 (tok/s)	26494.03 ★	7730.83

首Token延迟 (TTFT)

指标	NVIDIA_H100	Kunlun_P800
平均 TTFT (ms)	967.22 ★	1485.85
中位 TTFT (ms)	1032.07 ★	1296.89
P95 TTFT (ms)	1697.66 ★	2324.89
P99 TTFT (ms)	2630.84 ★	9917.09

每Token生成时间 (TPOT)

指标	NVIDIA_H100	Kunlun_P800
平均 TPOT (ms)	21.13 ★	81.64
中位 TPOT (ms)	20.85 ★	82.49
P95 TPOT (ms)	23.79 ★	87.96
P99 TPOT (ms)	23.92 ★	92.41

Token间延迟 (ITL)

指标	NVIDIA_H100	Kunlun_P800
平均 ITL (ms)	21.27 ★	81.44
中位 ITL (ms)	13.09 ★	39.41
P95 ITL (ms)	150.58 ★	592.47
P99 ITL (ms)	161.83 ★	602.60

32 并发

服务基准结果

指标	NVIDIA_H100	Kunlun_P800
成功请求数	320	320
失败请求数	0	0
测试持续时间 (s)	102.68	352.75
总输入 tokens	3289280	3276748
总生成 tokens	81920	78933
请求吞吐量 (req/s)	3.12 ★	0.91
输出 token 吞吐量 (tok/s)	797.81 ★	223.77
峰值输出 token 吞吐量 (tok/s)	1920.00 ★	702.00
峰值并发请求数	40.00	36.00
总 token 吞吐量 (tok/s)	32831.81 ★	9513.02

首Token延迟 (TTFT)

指标	NVIDIA_H100	Kunlun_P800
平均 TTFT (ms)	1227.85 ★	2848.93
中位 TTFT (ms)	968.59 ★	1715.48
P95 TTFT (ms)	3978.00 ★	12301.42
P99 TTFT (ms)	6556.86 ★	22359.61

每Token生成时间 (TPOT)

指标	NVIDIA_H100	Kunlun_P800
平均 TPOT (ms)	35.33 ★	130.25
中位 TPOT (ms)	36.07 ★	135.10
P95 TPOT (ms)	38.47 ★	145.12
P99 TPOT (ms)	38.79 ★	163.15

Token间延迟 (ITL)

指标	NVIDIA_H100	Kunlun_P800
平均 ITL (ms)	35.48 ★	130.13
中位 ITL (ms)	16.79 ★	47.63
P95 ITL (ms)	161.31 ★	608.17
P99 ITL (ms)	166.38 ★	619.41

64 并发

服务基准结果

指标	NVIDIA_H100	Kunlun_P800
成功请求数	320	320
失败请求数	0	0
测试持续时间 (s)	87.41	314.19
总输入 tokens	3289280	3276748
总生成 tokens	81920	79780
请求吞吐量 (req/s)	3.66 ★	1.02
输出 token 吞吐量 (tok/s)	937.16 ★	253.92
峰值输出 token 吞吐量 (tok/s)	2878.00 ★	1024.00
峰值并发请求数	72.00	68.00
总 token 吞吐量 (tok/s)	38566.45 ★	10682.97

首Token延迟 (TTFT)

指标	NVIDIA_H100	Kunlun_P800
平均 TTFT (ms)	2119.88 ★	6916.51
中位 TTFT (ms)	981.41 ★	2495.19
P95 TTFT (ms)	10055.31 ★	38095.53
P99 TTFT (ms)	12557.76 ★	47912.19

每Token生成时间 (TPOT)

指标	NVIDIA_H100	Kunlun_P800
平均 TPOT (ms)	59.72 ★	222.66
中位 TPOT (ms)	63.77 ★	241.15
P95 TPOT (ms)	64.94 ★	253.91
P99 TPOT (ms)	66.03 ★	271.54

Token间延迟 (ITL)

指标	NVIDIA_H100	Kunlun_P800
平均 ITL (ms)	60.01 ★	222.08
中位 ITL (ms)	22.71 ★	65.24
P95 ITL (ms)	166.68 ★	631.09
P99 ITL (ms)	170.95 ★	635.84

80 并发

服务基准结果

指标	NVIDIA_H100	Kunlun_P800
成功请求数	320	320
失败请求数	0	0
测试持续时间 (s)	87.25	315.14
总输入 tokens	3289280	3276748
总生成 tokens	81920	80493
请求吞吐量 (req/s)	3.67 ★	1.02
输出 token 吞吐量 (tok/s)	938.91 ★	255.42
峰值输出 token 吞吐量 (tok/s)	2880.00 ★	1025.00
峰值并发请求数	86.00	83.00
总 token 吞吐量 (tok/s)	38638.21 ★	10653.29

首Token延迟 (TTFT)

指标	NVIDIA_H100	Kunlun_P800
平均 TTFT (ms)	5759.41 ★	21074.74
中位 TTFT (ms)	3936.04 ★	15109.31
P95 TTFT (ms)	13080.99 ★	50874.99
P99 TTFT (ms)	19679.20 ★	71633.46

每Token生成时间 (TPOT)

指标	NVIDIA_H100	Kunlun_P800
平均 TPOT (ms)	61.00 ★	223.83
中位 TPOT (ms)	65.44 ★	243.06
P95 TPOT (ms)	65.70 ★	251.21
P99 TPOT (ms)	66.45 ★	255.96

Token间延迟 (ITL)

指标	NVIDIA_H100	Kunlun_P800
平均 ITL (ms)	61.40 ★	223.17
中位 ITL (ms)	22.72 ★	65.36
P95 ITL (ms)	167.68 ★	630.93
P99 ITL (ms)	171.22 ★	638.32

128 并发

服务基准结果

指标	NVIDIA_H100	Kunlun_P800
成功请求数	320	320
失败请求数	0	0
测试持续时间 (s)	87.37	314.72
总输入 tokens	3289280	3276748
总生成 tokens	81920	80186
请求吞吐量 (req/s)	3.66 ★	1.02
输出 token 吞吐量 (tok/s)	937.61 ★	254.79
峰值输出 token 吞吐量 (tok/s)	2874.00 ★	1024.00
峰值并发请求数	134.00	131.00
总 token 吞吐量 (tok/s)	38585.00 ★	10666.52

首Token延迟 (TTFT)

指标	NVIDIA_H100	Kunlun_P800
平均 TTFT (ms)	16764.52 ★	60948.41
中位 TTFT (ms)	17718.86 ★	63459.09
P95 TTFT (ms)	27005.85 ★	101009.77
P99 TTFT (ms)	29645.32 ★	110786.32

每Token生成时间 (TPOT)

指标	NVIDIA_H100	Kunlun_P800
平均 TPOT (ms)	61.07 ★	224.66
中位 TPOT (ms)	65.51 ★	241.98
P95 TPOT (ms)	65.86 ★	251.19
P99 TPOT (ms)	66.52 ★	325.18

Token间延迟 (ITL)

指标	NVIDIA_H100	Kunlun_P800
平均 ITL (ms)	61.61 ★	223.47
中位 ITL (ms)	22.76 ★	65.31
P95 ITL (ms)	167.75 ★	627.22
P99 ITL (ms)	170.62 ★	635.16

报告生成时间: 2026-05-25