

MiniMax-M2.5模型在Hygon_BW1000上的RUN-ID对比报告

测试日期： 2026-03-31

对比RUN-ID： 01 vs 02

测试场景

对比同一芯片、同一测试套件下,同一模型优化前后超长上下文测试结果比对，分析性能差异。

测试模型

第一轮测试（RUN-01）：MiniMax-M2.5-bf16

第二轮测试（RUN-02）：MiniMax-M2.5-W8A8

vLLM启动配置信息

参数名称	RUN-01	RUN-02
max-model-len	196608	196608
max-num-seqs	64	64
max-num-batched-tokens	8192	N/A
gpu-memory-utilization	0.95	0.9
dp	1	1
tp	8	8
pp	1	1
enable-export-parallel	False	N/A
tool-call-parser	minimax_m2	minimax_m2
reasoning-parser	minimax_m2	N/A
-cc	N/A	{"pass_config": {"fuse_act_quant": false}}



测试概览

项目	配置	备注
数据集	random	
并发数	[32]	
总请求数	[1000]	
请求输入上下文长度	[90000]	
请求输出上下文长度	[2000]	
模型	MiniMax-M2.5	
被测芯片	Hygon_BW1000	

主要采集指标：

指标	单位	含义
TTFT	ms	Time To First Token，首 token 延迟
TPOT	ms/token	Time Per Output Token，每 token 生成时间
Throughput	tokens/s	系统总吞吐
QPS	requests/s	请求吞吐
P50/P95/P99 Latency	ms	延迟分位数

各并发级别详细对比

并发级别: 32

服务基准结果

指标	RUN-01	RUN-02	差异	百分比
成功请求数	1000	1000	0.00	0.0%
失败请求数	0	0	0.00	0.0%
测试持续时间 (s)	60102.65	34205.42	-25897.23	-43.1%
总输入 tokens	90000000	90000000	0.00	0.0%
总生成 tokens	323447	2000000	+1676553.00	+518.3%
请求吞吐量 (req/s)	0.02	0.03	+0.01	+50.0%
输出 token 吞吐量 (tok/s)	5.38	58.47	+53.09	+986.8%
峰值输出 token 吞吐量 (tok/s)	15.00	256.00	+241.00	+1606.7%
峰值并发请求数	34.00	33.00	-1.00	-2.9%
总 token 吞吐量 (tok/s)	1502.82	2689.63	+1186.81	+79.0%

首Token延迟 (TTFT)

指标	RUN-01	RUN-02	差异	百分比
平均 TTFT (ms)	1813110.36	762454.48	-1050655.88	-57.9%
中位 TTFT (ms)	1826584.99	757405.72	-1069179.27	-58.5%
P95 TTFT (ms)	2098647.67	837892.19	-1260755.48	-60.1%
P99 TTFT (ms)	2179511.94	839223.46	-1340288.48	-61.5%


每Token生成时间 (TPOT)

指标	RUN-01	RUN-02	差异	百分比
平均 TPOT (ms)	270.88	161.82	-109.06	-40.3%
中位 TPOT (ms)	275.03	162.74	-112.29	-40.8%
P95 TPOT (ms)	441.40	163.57	-277.83	-62.9%
P99 TPOT (ms)	540.88	164.10	-376.78	-69.7%

Token间延迟 (ITL)

指标	RUN-01	RUN-02	差异	百分比
平均 ITL (ms)	265.46	161.76	-103.70	-39.1%
中位 ITL (ms)	159.79	41.19	-118.60	-74.2%
P95 ITL (ms)	167.54	48.99	-118.55	-70.8%
P99 ITL (ms)	2310.17	2598.52	+288.35	+12.5%

 RUN-ID对比柱状图



 分析总结

吞吐量对比

请求吞吐量: RUN-02 相比 RUN-01 平均提升 **50.0%**

输出Token吞吐量: RUN-02 相比 RUN-01 平均提升 **986.8%**

延迟对比

TTFT P99: RUN-02 相比 RUN-01 平均改善 **61.5%** (延迟降低)

TPOT P99: RUN-02 相比 RUN-01 平均改善 **69.7%** (延迟降低)

ITL P99: RUN-02 相比 RUN-01 平均增加 **12.5%** (延迟增加)

报告生成时间: 2026-03-31