

MiniMax-M2.5模型在NVIDIA_H100上的Benchmark基准测试报告

测试日期： 2026-05-06

测试场景

在固定请求数，输入上下文和输出上下文长度下，使用vllm bench serve工具对并发数逐级增加场景的性能基准验证。分析同一芯片同一模型在不同并发级别下的性能指标变化趋势。

主要采集指标：

指标	单位	含义
TTFT	ms	Time To First Token，首 token 延迟
TPOT	ms/token	Time Per Output Token，每 token 生成时间
Throughput	tokens/s	系统总吞吐
QPS	requests/s	请求吞吐
P50/P95/P99 Latency	ms	延迟分位数



测试概览

项目	配置	备注
数据集	random	
并发数	1, 2, 4, 8, 10, 16, 32, 64, 80, 128	
总请求数	320	
请求输入上下文长度	10240 (10k)	
请求输出上下文长度	256 (0.25k)	
模型	MiniMax-M2.5	
被测芯片	NVIDIA_H100	

芯片和模型配置信息

参数名称	NVIDIA_H100
model_name	MiniMax-M2.5
quantization_config	FP16
model_size	215G
max_position_embeddings	196608
temperature	N/A
top_k	N/A
top_p	N/A
transformers_version	4.46.1
vllm_version	0.15.1
python_version	3.12.3

 vLLM启动配置信息

参数名称	NVIDIA_H100
model_name	MiniMax-M2.5
max-model-len	196608
max-num-seqs	10
max-num-batched-tokens	8192
gpu-memory-utilization	0.85
dtype	default
block_size	default
dp	1
tp	8
pp	1
enable-export-parallel	True
enable-auto-tool-choice	True
tool-call-parser	minimax_m2
reasoning-parser	minimax_m2

- **NVIDIA_H100:** 英伟达H100标准配置

服务基准结果

指标	1 并发	2 并发	4 并发	8 并发	10 并发	16 并发	32 并发	64 并发
成功请求数	320	320	320	320	320	320	320	320
失败请求数	0	0	0	0	0	0	0	0
测试持续时间 (s)	710.45	410.23	253.27	175.80	153.26	127.24	102.68	87.41
总输入 tokens	3289280	3289280	3289280	3289280	3289280	3289280	3289280	3289280
总生成 tokens	81920	81920	81920	81920	81920	81920	81920	81920
请求吞吐量 (req/s)	0.45	0.78	1.26	1.82	2.09	2.51	3.12	3.66
输出 token 吞吐量 (tok/s)	115.31	199.70	323.45	465.99	534.52	643.80	797.81	937.16
峰值输出 token 吞吐量 (tok/s)	132.00	244.00	436.00	760.00	900.00	1248.00	1920.00	2878.00
峰值并发请求数	2.00	4.00	8.00	16.00	19.00	26.00	40.00	72.00
总 token 吞吐量 (tok/s)	4745.14	8217.92	13310.92	19176.39	21996.95	26494.03	32831.81	38566.45

🕒 首Token延迟 (TTFT)

指标	1 并发	2 并发	4 并发	8 并发	10 并发	16 并发	32 并发	64 并发	80 并发
平均 TTFT (ms)	264.19	360.79	584.15	931.63	827.89	967.22	1227.85	2119.88	5759.41
中位 TTFT (ms)	264.45	284.36	582.44	935.84	875.37	1032.07	968.59	981.41	3936.04
P95 TTFT (ms)	275.76	463.55	821.10	1245.61	1309.06	1697.66	3978.00	10055.31	13080.99
P99 TTFT (ms)	286.01	466.40	826.89	1364.44	1534.23	2630.84	6556.86	12557.76	19679.20

⚡ 每Token生成时间 (TPOT)

指标	1 并发	2 并发	4 并发	8 并发	10 并发	16 并发	32 并发	64 并发	80 并发	128 并发
平均 TPOT (ms)	7.67	8.64	10.12	13.58	15.52	21.13	35.33	59.72	61.00	61.07
中位 TPOT (ms)	7.67	8.65	10.02	13.24	15.31	20.85	36.07	63.77	65.44	65.51
P95 TPOT (ms)	7.68	9.04	11.39	15.59	17.71	23.79	38.47	64.94	65.70	65.86
P99 TPOT (ms)	7.68	9.05	11.41	35.95	17.75	23.92	38.79	66.03	66.45	66.52


Token间延迟 (ITL)

指标	1 并发	2 并发	4 并发	8 并发	10 并发	16 并发	32 并发	64 并发	80 并发	128 并发
平均 ITL (ms)	7.70	8.68	10.20	13.66	15.60	21.27	35.48	60.01	61.40	61.61
中位 ITL (ms)	7.69	8.28	9.24	10.60	11.23	13.09	16.79	22.71	22.72	22.76
P95 ITL (ms)	7.83	8.46	9.57	11.15	12.43	150.58	161.31	166.68	167.68	167.75
P99 ITL (ms)	8.57	16.54	18.61	152.68	155.84	161.83	166.38	170.95	171.22	170.62




各并发级别性能柱状图

MiniMax-M2.5 on NVIDIA_H100 - Concurrency Comparison



性能趋势分析

MiniMax-M2.5 on NVIDIA_H100 - Performance Trends by Concurrency



分析总结

1. 吞吐量性能分析

请求吞吐量 (QPS): 随着并发级别增加, QPS持续上升。低并发(1,2,4)平均 QPS: 0.83 req/s; 中并发(8,10,16,32)平均 QPS: 2.38 req/s; 高并发(64,80,128)平均 QPS: 3.66 req/s; 最高 QPS 出现在 80 并发, 达到 3.67 req/s。

Token总吞吐量: 最高达到 38638 tok/s (80 并发)。

2. 首Token延迟 (TTFT) 分析

TTFT随并发增加显著上升。低并发平均 P99 TTFT: 526ms; 高并发平均 P99 TTFT: 20627ms; 最高 P99 TTFT 出现在 128 并发, 达到 29645ms。

3. Token生成时间 (TPOT) 分析

TPOT随并发增加也呈上升趋势。低并发平均 P99 TPOT: 9.38ms; 高并发平均 P99 TPOT: 66.33ms; 最高 P99 TPOT 出现在 128 并发, 达到 66.52ms。

4. Token间延迟 (ITL) 分析

ITL随并发增加呈上升趋势。低并发平均 P99 ITL: 14.57ms；高并发平均 P99 ITL: 170.93ms；最高 P99 ITL 出现在 80 并发，达到 171.22ms。

5. 综合评估

吞吐量增长: 从最低并发到最高并发，QPS增长了 713.3%。**TTFT延迟恶化:** 高并发相比低并发，TTFT P99增加了 5531.4%。**TPOT延迟恶化:** 高并发相比低并发，TPOT P99增加了 609.2%。

报告生成时间: 2026-05-06