

MiniMax-M2.5模型在不同平台下的benchmark和精度比对报告

测试日期: 2026-07-13

本测试报告中不同平台的部署框架

- NVIDIA_H100: vLLM
- kunlun_p800: vLLM
- tianjin_P800: SGLang
- hanggang_P800: SGLang

Benchmark测试

在固定请求数，输入上下文和输出上下文长度下，使用bench serve工具对并发数逐级增加场景的性能比对。

主要采集指标：

指标	单位	含义
TTFT	ms	Time To First Token，首 token 延迟
TPOT	ms/token	Time Per Output Token，每 token 生成时间
Throughput	tokens/s	系统总吞吐
QPS	requests/s	请求吞吐
P50/P95/P99 Latency	ms	延迟分位数

参数名称	nvidia_h100	kunlun_p800	tianjin_P800	hanggang_P800
max_position_embeddings	196608	196608	196608	196608
model_name	MiniMax-M2.5	MiniMax-M2.5-W8A8-INT8-Dynamic	MiniMax-M2.5-int8	MiniMax-M2.5-int8
model_size	215G	215G	215G	215G
python_version	3.12.3	3.10.15	3.10.19	3.10.19
quantization_config	FP8	w8a8_int8	w8a8_int8	w8a8_int8
temperature	1.0	1.0	1.0	1.0
top_k	40	40	40	40
top_p	0.95	0.95	0.95	0.95
transformers_version	4.46.1	4.46.1	4.46.1	4.46.1
vllm_version	0.20.0	0.11.0	N/A	N/A
sglang_version	N/A	N/A	0.5.10+08768c8f9	0.5.10+08768c8f9

九章云极

参数名称	nvidia_h100	kunlun_p800	tianjin_P800	hanggang_P800
Attention Backend	N/A	N/A	kunlun	kunlun
Context Length	196608	196608	196608	196608
DP Size	1	1	1	1
PP Size	1	1	1	1
TP Size	8	8	8	8
EP Size	N/A	N/A	8	8
Block Size	default	128	N/A	N/A
Dtype	default	auto	bfloat16	bfloat16
Max Running Requests	64	64	64	64
Gpu Memory Utilization	0.85	0.95	0.85	0.85
Chunked Prefill Size	N/A	N/A	8192	8192
Max Num Batched Tokens	8192	8192	N/A	N/A
Cuda Graph Max Bs	N/A	N/A	128	128
Disable Radix Cache	N/A	N/A	True	True
Disable Radix Cache	N/A	N/A	True	True
Reasoning Parser	minimax_m2	minimax_m2	minimax	minimax
Tool Call Parser	minimax_m2	minimax_m2	minimax_m2	minimax_m2

tianjin_P800和hanggang_P800环境的启动部署详细命令见《附录一》

测试场景一：短上下文


benchmark测试命令见《附录二》

🌈 测试概览


项目	配置	备注
数据集	random	
并发数	1, 64	
总请求数	320	
请求输入上下文长度	10240 (10k)	
请求输出上下文长度	256 (0.25k)	
被测芯片	nvidia_h100, kunlun_p800, tianjin_P800, hanggang_P800	
被测模型	MiniMax-M2.5	

芯片性能对比柱状图

1并发



64并发



请求吞吐量（Request throughput (req/s)）

并发数	nvidia_h100(基准)	kunlun_p800	相对基准	tianjin_P800	相对基准	hanggang_P800	相对基准
1	0.45	0.15	-66.7%	0.64	+42.2%	0.58	+28.9%
64	3.66	1.02	-72.1%	3.73	+1.9%	3.23	-11.7%

输出token吞吐量（Output token throughput (tok/s)）

并发数	nvidia_h100(基准)	kunlun_p800	相对基准	tianjin_P800	相对基准	hanggang_P800	相对基准
1	115.31	37.20	-67.7%	83.01	-28.0%	74.83	-35.1%
64	937.16	253.92	-72.9%	485.48	-48.2%	416.15	-55.6%

总token吞吐量（Total token throughput (tok/s)）

并发数	nvidia_h100(基准)	kunlun_p800	相对基准	tianjin_P800	相对基准	hanggang_P800	相对基准
1	4745.14	1585.87	-66.6%	3269.11	-31.1%	3044.41	-35.8%
64	38566.45	10682.97	-72.3%	19118.70	-50.4%	16929.83	-56.1%

首token延迟（P99 TTFT (ms)）

并发数	nvidia_h100(基准)	kunlun_p800	相对基准	tianjin_P800	相对基准	hanggang_P800	相对基准
1	286.01	921.76	+222.3%	1972.91	+589.8%	2188.87	+665.3%
64	12557.76	47912.19	+281.5%	22001.51	+75.2%	31429.92	+150.3%

每token生成时间（P99 TPOT (ms)）

并发数	nvidia_h100(基准)	kunlun_p800	相对基准	tianjin_P800	相对基准	hanggang_P800	相对基准
1	7.68	23.38	+204.4%	75.54	+883.6%	114.31	+1388.4%
64	66.03	271.54	+311.2%	605.44	+816.9%	701.16	+961.9%

并发数	nvidia_h100(基准)	kunlun_p800	相对基准	tianjin_P800	相对基准	hanggang_P800	相对基准
1	8.57	24.07	+180.9%	107.20	+1150.9%	31.97	+273.0%
64	170.95	635.84	+271.9%	532.30	+211.4%	802.92	+369.7%

测试场景二： 超长上下文


测试概览

项目	配置	备注
数据集	random	
并发数	1, 10	
总请求数	100	
请求输入上下文长度	194560 (190k)	
请求输出上下文长度	1024 (1k)	
被测芯片	nvidia_h100, kunlun_p800, tianjin_P800, hanggang_P800	
被测模型	MiniMax-M2.5	


芯片性能对比柱状图

1并发

MiniMax-M2.5 Chip Comparison @ 1 Concurrency



MiniMax-M2.5 Chip Comparison @ 10 Concurrency



请求吞吐量（Request throughput (req/s)）

并发数	nvidia_h100(基准)	kunlun_p800	相对基准	tianjin_P800	相对基准	hanggang_P800	相对基准
1	0.05	0.02	-60.0%	0.07	+40.0%	0.07	+40.0%
10	0.07	0.02	-71.4%	0.10	+42.9%	0.10	+42.9%

输出token吞吐量（Output token throughput (tok/s)）

并发数	nvidia_h100(基准)	kunlun_p800	相对基准	tianjin_P800	相对基准	hanggang_P800	相对基准
1	46.70	2.92	-93.7%	35.49	-24.0%	33.72	-27.8%
10	75.37	3.70	-95.1%	51.02	-32.3%	51.09	-32.2%

总token吞吐量（Total token throughput (tok/s)）

并发数	nvidia_h100(基准)	kunlun_p800	相对基准	tianjin_P800	相对基准	hanggang_P800	相对基准
1	8921.40	3571.06	-60.0%	7023.45	-21.3%	6451.81	-27.7%
10	14398.41	4699.60	-67.4%	10098.73	-29.9%	9775.15	-32.1%

首token延迟（P99 TTFT (ms)）

并发数	nvidia_h100(基准)	kunlun_p800	相对基准	tianjin_P800	相对基准	hanggang_P800	相对基准
1	10539.10	40968.87	+288.7%	22758.65	+115.9%	25424.84	+141.2%
10	108342.29	337270.92	+211.3%	127473.40	+17.7%	123944.29	+14.4%

每token生成时间（P99 TPOT (ms)）

并发数	nvidia_h100(基准)	kunlun_p800	相对基准	tianjin_P800	相对基准	hanggang_P800	相对基准
1	11.39	89.90	+689.3%	2198.53	+19202.3%	387.43	+3301.5%
10	69.61	1792.32	+2474.8%	2293.63	+3195.0%	1239.19	+1680.2%

并发数	nvidia_h100(基准)	kunlun_p800	相对基准	tianjin_P800	相对基准	hanggang_P800	相对基准
1	22.97	93.69	+307.9%	44.22	+92.5%	49.10	+113.8%
10	639.97	2848.90	+345.2%	5670.42	+786.0%	5572.12	+770.7%

精度测试

天津和杭钢P800环境精度测试脚本见《附录三》

MiniMax-M2.5模型

Task	nvidia_h100(FP8)	kunlun_p800(W8A8-INT8-Dynamic)	百分比	tianjin_p800(W8A8-INT8)	差值	百分比
IFBench (Strict)	0.6067	0.6233	+ 2.75%	0.6967	0.0900	+ 14.84%
IFBench (Loose)	0.6433	0.6600	+ 2.59%	0.7400	0.0967	+ 15.03%
lm-eval:gsm_plus (Flexible)	0.6863	0.7398	+ 7.80%	0.7328	0.0465	+ 6.78%
lm-eval:gsm_plus (Strict)	0.7307	0.7251	- 0.77%	0.7010	-0.0297	- 4.06%
lm-eval:mmlu_pro	0.7378	0.6622	- 10.25%	0.6366	-0.1012	- 13.72%
lm-eval:ruler	0.5461	N/A	N/A	0.8926	0.3465	+ 63.44%

附录一：天津P800和杭钢P800环境的模型部署启动命令

```
#!/bin/bash
MODEL_DIR=${model_dir:-/work/models/ssd4/models/MiniMax-M2.5-int8}
DRAFT_MODEL_DIR=${draft_model_dir:-/work/models/ssd4/models/MiniMax-M2.5-Spec}

export LD_LIBRARY_PATH=${CONDA_PREFIX}/lib/python3.10/site-packages/xtorch_ops:${CONDA_PREFIX}/lib/python3.10/site-packages/nvidia/cuda_nvrtc/lib:${CONDA_PREFIX}/lib/python3.10/site-packages/torch_xmlir:/usr/local/cuda-11.7/:$LD_LIBRARY_PATH
export LD_LIBRARY_PATH=/usr/local/lib/:$LD_LIBRARY_PATH
```

```
export SGLANG_ENABLE_SPEC_V2=1
export SGLANG_ENABLE_OVERLAP_PLAN_STREAM=1
export BKCL_TREE_THRESHOLD=1048576
export CUDA_DEVICE_ORDER="OAM_ID"
export BKCL_INFERENCE=1
export XSGL_INTERTYPE_BFP16=1
export ENABLE_FAST_BFP16_ATTN=1
export USE_FAST_BFP16_MOE=1
export XSGL_FUSE_SPLIT_NORM_ROPE_NEOX=1
export USE_ALL_TO_ALL=1
export MIN_BATCH=32768
export XPUAPI_SDNN_BF16_ROUND_MODE=3
export XINFERENCE_QUANT_SDNN=1
export XPU_FLASH_ATTENTION_DECODER_USE_BALANCE=1
export XMLIR_ENABLE_FAST_FC=true
export XMLIR_FORCE_USE_XPU_GRAPH=1

nohup python -m sglang.launch_server \
  --host 0.0.0.0 \
  --model-path "$MODEL_DIR" \
  --tp-size 8 \
  --ep-size 8 \
  --kv-cache-dtype float16 \
  --trust-remote-code \
  --context-length 196608 \
  --attention-backend kunlun \
  --chunked-prefill-size 8192 \
  --page-size 64 \
  --mem-fraction-static 0.85 \
  --tool-call-parser minimax-m2 \
  --reasoning-parser minimax \
  --disable-overlap-schedule \
  --disable-radix-cache \
  --disable-custom-all-reduce \
  --max-running-requests 64 \
  --dtype bfloat16 \
  --cuda-graph-max-bs 128 \
  --speculative-algorithm EAGLE3 \
  --speculative-draft-model-path "$DRAFT_MODEL_DIR" \
  --speculative-num-steps 3 \
  --speculative-eagle-topk 1 \
  --watchdog-timeout 3000000 >log_$(date +"%Y%m%d").log 2>&1 &
```

附录二：benchmark测试执行命令

```
python3 -m sglang.bench_serving
  --backend sglang-oai-chat
  --base-url ${BASE_URL}
  --dataset-name random-ids
  --random-range-ratio 0.0
  --served-model-name ${MODEL}
  --random-input-len 10240
  --random-output-len 256
  --max-concurrency 1
  --num-prompt 320
  --model ${MODEL_PATH}
```

IFBench精度测试脚本

```
#!/bin/bash
ROOT_PATH=$(cd `dirname $0`; pwd)

echo $ROOT_PATH
cd ${ROOT_PATH}

CurDate=`date +%Y%m%d`

export NLTK_DATA=${ROOT_PATH}/nltk_data

API_BASE="${1:-http://127.0.0.1:30000/v1}"
API_KEY="${2:-abc123}"
MODEL="${3:-MiniMax-M2.5-int8}"

cat > .env << EOF
api_base=$API_BASE
api_key=$API_KEY
model=$MODEL
temperature=1.0
top_p=0.95
top_k=40
max_tokens=16384
seed=42
input_file=data/IFBench_test.jsonl
output_file=data/${MODEL}-responses.jsonl
workers=8
EOF

# 2. 生成模型响应
uv run python3 generate_responses.py

# 快速测试
#uv run python generate_responses.py --limit 5

# 3. Thinking 模型后处理（重要！）
uv run python3 postprocess_thinking.py data/${MODEL}-responses.jsonl -o data/${MODEL}-clean.jsonl

# 4. 运行评估
uv run python3 -m run_eval \
    --input_data=data/IFBench_test.jsonl \
    --input_response_data=data/${MODEL}-clean.jsonl \
    --output_dir=eval
```

Im-eval精度测试脚本

```
#!/bin/bash
ROOT_PATH=$(cd `dirname $0`; pwd)

echo $ROOT_PATH
cd ${ROOT_PATH}

CurDate=$(date +%Y%m%d%H%M%S)
export HF_ENDPOINT=https://hf-mirror.com
```

```
ADDR=${ADDR:-127.0.0.1}
PORT=${PORT:-30000}
API_KEY=${API_KEY:-abc123}
LLM_ADDR="http://$ADDR:$PORT"
```

```
MODEL_NAME="/work/models/ssd4/models/MiniMax-M2.5-int8"
LOCAL_MODEL_PATH="/data1/dingjs/work/models/ssd4/models/MiniMax-M2.5-int8"
```

```
# model_args 构造
```

```
MODEL_ARGS_BASE_1="
```

```
{\"model\": \"$MODEL_NAME\", \"base_url\": \"$LLM_ADDR/v1/completions\", \"max_length\": 131072, \"tokenizer\": \"$LOCAL_MODEL_PATH\", \"trust_remote_code\": true, \"num_concurrent\": 10, \"max_retries\": 3, \"timeout\": 12000, \"tokenized_requests\": false, \"headers\": {\"Authorization\": \"Bearer $API_KEY\"}}"
```

```
MODEL_ARGS_BASE_2="
```

```
{\"model\": \"$MODEL_NAME\", \"base_url\": \"$LLM_ADDR/v1/completions\", \"max_length\": 192512, \"tokenizer\": \"$LOCAL_MODEL_PATH\", \"trust_remote_code\": true, \"num_concurrent\": 10, \"max_retries\": 3, \"timeout\": 12000, \"tokenized_requests\": false, \"headers\": {\"Authorization\": \"Bearer $API_KEY\"}}"
```

```
# 运行单个任务的函数
```

```
run_task_1() {
```

```
    local task_name=$1
    local max_tokens=$2
    local temperature=$3
    local unsafe_code=$4
```

```
    local do_sample="false"
```

```
    [ "$temperature" = "1.0" ] && do_sample="true"
```

```
    GEN_KWARGS="
```

```
{\"max_gen_toks\": $max_tokens, \"do_sample\": $do_sample, \"temperature\": $temperature, \"top_p\": 0.95, \"top_k\": 40}"
```

```
    local unsafe_flag=""
```

```
    [ "$unsafe_code" = "true" ] && unsafe_flag="--confirm_run_unsafe_code" && export HF_ALLOW_CODE_EVAL=1
```

```
    lm_eval \
```

```
        --model local-completions \
        --tasks $task_name \
        --output_path ./output/${task_name}/mm25_${CurDate} \
        --model_args "$MODEL_ARGS_BASE_1" \
        --batch_size auto \
        --gen_kwargs "$GEN_KWARGS" \
        $unsafe_flag
```

```
}
```

```
run_task_2() {
```

```
    local task_name=$1
    local max_tokens=$2
    local temperature=$3
    local unsafe_code=$4
```

```
    local do_sample="false"
```

```
    [ "$temperature" = "1.0" ] && do_sample="true"
```

```
    GEN_KWARGS="
```

```
{\"max_gen_toks\": $max_tokens, \"do_sample\": $do_sample, \"temperature\": $temperature, \"top_p\": 0.95, \"top_k\": 40}"
```

```
    local unsafe_flag=""
```

```
    [ "$unsafe_code" = "true" ] && unsafe_flag="--confirm_run_unsafe_code" && export HF_ALLOW_CODE_EVAL=1
```

```
lm_eval \
--model local-completions \
--tasks $task_name \
--output_path ./output/${task_name}/mm25_${CurDate} \
--model_args "$MODEL_ARGS_BASE_2" \
--batch_size auto \
--limit 32 \
--gen_kwargs "$GEN_KWARGS" \
$unsafe_flag
}
```

```
run_task_1 mmlu_pro 8192 0.0 false
```

```
sleep 120
```

```
run_task_1 gsm_plus 8192 0.0 false
```

```
sleep 120
```

```
run_task_2 ruler 8192 0.0 false
```

报告生成时间: 2026-07-13

九章云极