

MiniMax-M2.5模型在单节点Hygon_BW1000上benchmark基准测试优化前后对比报告

测试日期： 2026-03-31

对比RUN-ID： 01 vs 02

测试场景

对比同一芯片、同一测试套件下,同一模型优化前后benchmark基准性能测试结果比对，分析性能差异。

测试模型

第一轮测试（RUN-01）：MiniMax-M2.5-bf16

第二轮测试（RUN-02）：MiniMax-M2.5-W8A8

vLLM启动配置信息

参数名称	RUN-01	RUN-02
max-model-len	196608	196608
max-num-seqs	10	64
max-num-batched-tokens	8192	N/A
gpu-memory-utilization	0.95	0.9
dp	1	1
tp	8	8
pp	1	1
enable-export-parallel	False	N/A
tool-call-parser	minimax_m2	minimax_m2
reasoning-parser	minimax_m2	N/A
-cc	N/A	{"pass_config": {"fuse_act_quant": false}}

测试概览

项目	配置	备注
数据集	random	
并发数	[1, 2, 4, 8, 10, 16, 32, 64, 80, 128]	
总请求数	[320]	
请求输入上下文长度	[10240]	
请求输出上下文长度	[256]	
模型	MiniMax-M2.5	
被测芯片	Hygon_BW1000	

主要采集指标：

指标	单位	含义
TTFT	ms	Time To First Token，首 token 延迟
TPOT	ms/token	Time Per Output Token，每 token 生成时间
Throughput	tokens/s	系统总吞吐
QPS	requests/s	请求吞吐
P50/P95/P99 Latency	ms	延迟分位数

各并发级别详细对比

并发级别: 1

服务基准结果

指标	RUN-01	RUN-02	差异	百分比
成功请求数	320	320	0.00	0.0%
失败请求数	0	0	0.00	0.0%
测试持续时间 (s)	13148.00	1523.87	-11624.13	-88.4%
总输入 tokens	3276748	3276800	+52.00	+0.0%
总生成 tokens	80226	81920	+1694.00	+2.1%
请求吞吐量 (req/s)	0.02	0.21	+0.19	+950.0%
输出 token 吞吐量 (tok/s)	6.10	53.76	+47.66	+781.3%
峰值输出 token 吞吐量 (tok/s)	8.00	71.00	+63.00	+787.5%
峰值并发请求数	2.00	2.00	0.00	0.0%
总 token 吞吐量 (tok/s)	255.32	2204.07	+1948.75	+763.3%

首Token延迟 (TTFT)

指标	RUN-01	RUN-02	差异	百分比
平均 TTFT (ms)	1958.35	1107.56	-850.79	-43.4%
中位 TTFT (ms)	1964.30	1112.30	-852.00	-43.4%
P95 TTFT (ms)	1977.98	1121.88	-856.10	-43.3%
P99 TTFT (ms)	1990.88	1124.29	-866.59	-43.5%

每Token生成时间 (TPOT)

指标	RUN-01	RUN-02	差异	百分比
平均 TPOT (ms)	156.69	14.33	-142.36	-90.9%
中位 TPOT (ms)	156.16	14.33	-141.83	-90.8%
P95 TPOT (ms)	163.40	14.34	-149.06	-91.2%
P99 TPOT (ms)	168.81	14.35	-154.46	-91.5%

Token间延迟 (ITL)

指标	RUN-01	RUN-02	差异	百分比
平均 ITL (ms)	156.23	14.29	-141.94	-90.9%
中位 ITL (ms)	155.76	14.32	-141.44	-90.8%
P95 ITL (ms)	162.28	14.65	-147.63	-91.0%
P99 ITL (ms)	191.32	18.70	-172.62	-90.2%

并发级别: 2

服务基准结果

指标	RUN-01	RUN-02	差异	百分比
成功请求数	320	320	0.00	0.0%
失败请求数	0	0	0.00	0.0%
测试持续时间 (s)	6965.73	970.06	-5995.67	-86.1%
总输入 tokens	3276748	3276800	+52.00	+0.0%
总生成 tokens	80297	81920	+1623.00	+2.0%
请求吞吐量 (req/s)	0.05	0.33	+0.28	+560.0%
输出 token 吞吐量 (tok/s)	11.53	84.45	+72.92	+632.4%
峰值输出 token 吞吐量 (tok/s)	15.00	134.00	+119.00	+793.3%
峰值并发请求数	4.00	4.00	0.00	0.0%
总 token 吞吐量 (tok/s)	481.94	3462.37	+2980.43	+618.4%

首Token延迟 (TTFT)

指标	RUN-01	RUN-02	差异	百分比
平均 TTFT (ms)	2052.00	1625.47	-426.53	-20.8%
中位 TTFT (ms)	2024.87	1172.93	-851.94	-42.1%
P95 TTFT (ms)	2038.41	2151.08	+112.67	+5.5%
P99 TTFT (ms)	3752.70	2154.58	-1598.12	-42.6%

每Token生成时间 (TPOT)

指标	RUN-01	RUN-02	差异	百分比
平均 TPOT (ms)	165.84	17.40	-148.44	-89.5%
中位 TPOT (ms)	166.01	15.56	-150.45	-90.6%
P95 TPOT (ms)	168.30	19.54	-148.76	-88.4%
P99 TPOT (ms)	173.26	19.59	-153.67	-88.7%

Token间延迟 (ITL)

指标	RUN-01	RUN-02	差异	百分比
平均 ITL (ms)	165.31	17.34	-147.97	-89.5%
中位 ITL (ms)	158.87	15.35	-143.52	-90.3%
P95 ITL (ms)	164.70	16.15	-148.55	-90.2%
P99 ITL (ms)	168.68	16.62	-152.06	-90.1%

并发级别: 4

服务基准结果

指标	RUN-01	RUN-02	差异	百分比
成功请求数	320	320	0.00	0.0%
失败请求数	0	0	0.00	0.0%
测试持续时间 (s)	3741.16	672.39	-3068.77	-82.0%
总输入 tokens	3276748	3276800	+52.00	+0.0%
总生成 tokens	80266	81920	+1654.00	+2.1%
请求吞吐量 (req/s)	0.09	0.48	+0.39	+433.3%
输出 token 吞吐量 (tok/s)	21.45	121.83	+100.38	+468.0%
峰值输出 token 吞吐量 (tok/s)	29.00	247.00	+218.00	+751.7%
峰值并发请求数	7.00	8.00	+1.00	+14.3%
总 token 吞吐量 (tok/s)	897.32	4995.17	+4097.85	+456.7%

首Token延迟 (TTFT)

指标	RUN-01	RUN-02	差异	百分比
平均 TTFT (ms)	2185.58	3362.79	+1177.21	+53.9%
中位 TTFT (ms)	2038.85	4126.05	+2087.20	+102.4%
P95 TTFT (ms)	3821.77	4132.31	+310.54	+8.1%
P99 TTFT (ms)	5568.67	4142.31	-1426.36	-25.6%

每Token生成时间 (TPOT)

指标	RUN-01	RUN-02	差异	百分比
平均 TPOT (ms)	177.49	19.77	-157.72	-88.9%
中位 TPOT (ms)	177.87	16.88	-160.99	-90.5%
P95 TPOT (ms)	183.40	28.70	-154.70	-84.4%
P99 TPOT (ms)	186.11	28.81	-157.30	-84.5%

Token间延迟 (ITL)

指标	RUN-01	RUN-02	差异	百分比
平均 ITL (ms)	176.98	19.70	-157.28	-88.9%
中位 ITL (ms)	157.22	16.81	-140.41	-89.3%
P95 ITL (ms)	162.59	17.70	-144.89	-89.1%
P99 ITL (ms)	1872.44	20.16	-1852.28	-98.9%

并发级别: 8

服务基准结果

指标	RUN-01	RUN-02	差异	百分比
成功请求数	320	320	0.00	0.0%
失败请求数	0	0	0.00	0.0%
测试持续时间 (s)	2176.31	522.12	-1654.19	-76.0%
总输入 tokens	3276748	3276800	+52.00	+0.0%
总生成 tokens	80442	81920	+1478.00	+1.8%
请求吞吐量 (req/s)	0.15	0.61	+0.46	+306.7%
输出 token 吞吐量 (tok/s)	36.96	156.90	+119.94	+324.5%
峰值输出 token 吞吐量 (tok/s)	59.00	431.00	+372.00	+630.5%
峰值并发请求数	15.00	16.00	+1.00	+6.7%
总 token 吞吐量 (tok/s)	1542.60	6432.85	+4890.25	+317.0%

首Token延迟 (TTFT)

指标	RUN-01	RUN-02	差异	百分比
平均 TTFT (ms)	3297.61	7177.32	+3879.71	+117.7%
中位 TTFT (ms)	2089.60	8080.61	+5991.01	+286.7%
P95 TTFT (ms)	10888.09	8091.51	-2796.58	-25.7%
P99 TTFT (ms)	13004.02	8121.50	-4882.52	-37.5%

每Token生成时间 (TPOT)

指标	RUN-01	RUN-02	差异	百分比
平均 TPOT (ms)	201.95	23.04	-178.91	-88.6%
中位 TPOT (ms)	205.98	19.57	-186.41	-90.5%
P95 TPOT (ms)	212.79	46.84	-165.95	-78.0%
P99 TPOT (ms)	221.53	47.06	-174.47	-78.8%

Token间延迟 (ITL)

指标	RUN-01	RUN-02	差异	百分比
平均 ITL (ms)	201.36	22.98	-178.38	-88.6%
中位 ITL (ms)	157.25	19.65	-137.60	-87.5%
P95 ITL (ms)	163.19	20.51	-142.68	-87.4%
P99 ITL (ms)	1931.02	28.16	-1902.86	-98.5%

并发级别: 10

服务基准结果

指标	RUN-01	RUN-02	差异	百分比
成功请求数	320	320	0.00	0.0%
失败请求数	0	0	0.00	0.0%
测试持续时间 (s)	1854.59	526.35	-1328.24	-71.6%
总输入 tokens	3276748	3276800	+52.00	+0.0%
总生成 tokens	80517	81920	+1403.00	+1.7%
请求吞吐量 (req/s)	0.17	0.61	+0.44	+258.8%
输出 token 吞吐量 (tok/s)	43.42	155.64	+112.22	+258.5%
峰值输出 token 吞吐量 (tok/s)	73.00	420.00	+347.00	+475.3%
峰值并发请求数	16.00	20.00	+4.00	+25.0%
总 token 吞吐量 (tok/s)	1810.25	6381.15	+4570.90	+252.5%

首Token延迟 (TTFT)

指标	RUN-01	RUN-02	差异	百分比
平均 TTFT (ms)	3593.83	9131.01	+5537.18	+154.1%
中位 TTFT (ms)	2084.97	10049.34	+7964.37	+382.0%
P95 TTFT (ms)	10884.20	10077.20	-807.00	-7.4%
P99 TTFT (ms)	16227.56	10093.60	-6133.96	-37.8%

每Token生成时间 (TPOT)

指标	RUN-01	RUN-02	差异	百分比
平均 TPOT (ms)	214.72	28.69	-186.03	-86.6%
中位 TPOT (ms)	219.17	25.26	-193.91	-88.5%
P95 TPOT (ms)	227.12	60.26	-166.86	-73.5%
P99 TPOT (ms)	234.69	60.57	-174.12	-74.2%

Token间延迟 (ITL)

指标	RUN-01	RUN-02	差异	百分比
平均 ITL (ms)	214.01	28.59	-185.42	-86.6%
中位 ITL (ms)	157.32	25.27	-132.05	-83.9%
P95 ITL (ms)	163.94	26.06	-137.88	-84.1%
P99 ITL (ms)	1924.45	31.38	-1893.07	-98.4%

并发级别: 16

服务基准结果

指标	RUN-01	RUN-02	差异	百分比
成功请求数	320	320	0.00	0.0%
失败请求数	0	0	0.00	0.0%
测试持续时间 (s)	1847.45	454.43	-1393.02	-75.4%
总输入 tokens	3276748	3276800	+52.00	+0.0%
总生成 tokens	80132	81920	+1788.00	+2.2%
请求吞吐量 (req/s)	0.17	0.70	+0.53	+311.8%
输出 token 吞吐量 (tok/s)	43.37	180.27	+136.90	+315.7%
峰值输出 token 吞吐量 (tok/s)	71.00	640.00	+569.00	+801.4%
峰值并发请求数	20.00	32.00	+12.00	+60.0%
总 token 吞吐量 (tok/s)	1817.04	7391.10	+5574.06	+306.8%

首Token延迟 (TTFT)

指标	RUN-01	RUN-02	差异	百分比
平均 TTFT (ms)	36634.82	15019.36	-21615.46	-59.0%
中位 TTFT (ms)	35931.86	15998.10	-19933.76	-55.5%
P95 TTFT (ms)	58125.31	16005.18	-42120.13	-72.5%
P99 TTFT (ms)	63884.93	16006.87	-47878.06	-74.9%

每Token生成时间 (TPOT)

指标	RUN-01	RUN-02	差异	百分比
平均 TPOT (ms)	216.95	30.19	-186.76	-86.1%
中位 TPOT (ms)	219.89	26.58	-193.31	-87.9%
P95 TPOT (ms)	228.33	84.64	-143.69	-62.9%
P99 TPOT (ms)	246.10	85.08	-161.02	-65.4%

Token间延迟 (ITL)

指标	RUN-01	RUN-02	差异	百分比
平均 ITL (ms)	216.16	30.08	-186.08	-86.1%
中位 ITL (ms)	157.71	26.71	-131.00	-83.1%
P95 ITL (ms)	164.13	28.05	-136.08	-82.9%
P99 ITL (ms)	1923.89	36.01	-1887.88	-98.1%

并发级别: 32

服务基准结果

指标	RUN-01	RUN-02	差异	百分比
成功请求数	320	320	0.00	0.0%
失败请求数	0	0	0.00	0.0%
测试持续时间 (s)	1847.10	417.58	-1429.52	-77.4%
总输入 tokens	3276748	3276800	+52.00	+0.0%
总生成 tokens	80324	81920	+1596.00	+2.0%
请求吞吐量 (req/s)	0.17	0.77	+0.60	+352.9%
输出 token 吞吐量 (tok/s)	43.49	196.18	+152.69	+351.1%
峰值输出 token 吞吐量 (tok/s)	71.00	896.00	+825.00	+1162.0%
峰值并发请求数	36.00	64.00	+28.00	+77.8%
总 token 吞吐量 (tok/s)	1817.48	8043.38	+6225.90	+342.6%

首Token延迟 (TTFT)

指标	RUN-01	RUN-02	差异	百分比
平均 TTFT (ms)	122875.63	30685.52	-92190.11	-75.0%
中位 TTFT (ms)	124891.14	31801.65	-93089.49	-74.5%
P95 TTFT (ms)	147416.43	31812.89	-115603.54	-78.4%
P99 TTFT (ms)	150615.03	31816.19	-118798.84	-78.9%

每Token生成时间 (TPOT)

指标	RUN-01	RUN-02	差异	百分比
平均 TPOT (ms)	218.56	43.40	-175.16	-80.1%
中位 TPOT (ms)	220.42	39.36	-181.06	-82.1%
P95 TPOT (ms)	227.78	39.76	-188.02	-82.5%
P99 TPOT (ms)	236.50	159.79	-76.71	-32.4%

Token间延迟 (ITL)

指标	RUN-01	RUN-02	差异	百分比
平均 ITL (ms)	217.96	43.23	-174.73	-80.2%
中位 ITL (ms)	157.77	39.61	-118.16	-74.9%
P95 ITL (ms)	165.32	40.89	-124.43	-75.3%
P99 ITL (ms)	1924.43	42.64	-1881.79	-97.8%

并发级别: 64

服务基准结果

指标	RUN-01	RUN-02	差异	百分比
成功请求数	320	320	0.00	0.0%
失败请求数	0	0	0.00	0.0%
测试持续时间 (s)	1864.45	388.79	-1475.66	-79.1%
总输入 tokens	3276748	3276800	+52.00	+0.0%
总生成 tokens	80461	81920	+1459.00	+1.8%
请求吞吐量 (req/s)	0.17	0.82	+0.65	+382.4%
输出 token 吞吐量 (tok/s)	43.16	210.71	+167.55	+388.2%
峰值输出 token 吞吐量 (tok/s)	71.00	1152.00	+1081.00	+1522.5%
峰值并发请求数	68.00	128.00	+60.00	+88.2%
总 token 吞吐量 (tok/s)	1800.65	8638.94	+6838.29	+379.8%

首Token延迟 (TTFT)

指标	RUN-01	RUN-02	差异	百分比
平均 TTFT (ms)	284382.45	62271.39	-222111.06	-78.1%
中位 TTFT (ms)	308175.63	63393.43	-244782.20	-79.4%
P95 TTFT (ms)	336951.30	63423.62	-273527.68	-81.2%
P99 TTFT (ms)	343209.29	63426.45	-279782.84	-81.5%

每Token生成时间 (TPOT)

指标	RUN-01	RUN-02	差异	百分比
平均 TPOT (ms)	218.23	60.67	-157.56	-72.2%
中位 TPOT (ms)	219.77	56.87	-162.90	-74.1%
P95 TPOT (ms)	231.26	57.06	-174.20	-75.3%
P99 TPOT (ms)	241.21	300.94	+59.73	+24.8%

Token间延迟 (ITL)

指标	RUN-01	RUN-02	差异	百分比
平均 ITL (ms)	217.55	60.44	-157.11	-72.2%
中位 ITL (ms)	157.89	57.12	-100.77	-63.8%
P95 ITL (ms)	168.53	63.94	-104.59	-62.1%
P99 ITL (ms)	1925.72	89.02	-1836.70	-95.4%

并发级别: 80

服务基准结果

指标	RUN-01	RUN-02	差异	百分比
成功请求数	320	320	0.00	0.0%
失败请求数	0	0	0.00	0.0%
测试持续时间 (s)	1847.88	389.10	-1458.78	-78.9%
总输入 tokens	3276748	3276800	+52.00	+0.0%
总生成 tokens	80365	81920	+1555.00	+1.9%
请求吞吐量 (req/s)	0.17	0.82	+0.65	+382.4%
输出 token 吞吐量 (tok/s)	43.49	210.54	+167.05	+384.1%
峰值输出 token 吞吐量 (tok/s)	71.00	1216.00	+1145.00	+1612.7%
峰值并发请求数	84.00	143.00	+59.00	+70.2%
总 token 吞吐量 (tok/s)	1816.74	8631.97	+6815.23	+375.1%

首Token延迟 (TTFT)

指标	RUN-01	RUN-02	差异	百分比
平均 TTFT (ms)	354268.91	77048.30	-277220.61	-78.3%
中位 TTFT (ms)	402242.69	62356.31	-339886.38	-84.5%
P95 TTFT (ms)	409210.34	140327.35	-268882.99	-65.7%
P99 TTFT (ms)	418658.91	140622.89	-278036.02	-66.4%

每Token生成时间 (TPOT)

指标	RUN-01	RUN-02	差异	百分比
平均 TPOT (ms)	217.84	64.19	-153.65	-70.5%
中位 TPOT (ms)	220.16	61.24	-158.92	-72.2%
P95 TPOT (ms)	227.98	61.41	-166.57	-73.1%
P99 TPOT (ms)	239.73	300.88	+61.15	+25.5%

Token间延迟 (ITL)

指标	RUN-01	RUN-02	差异	百分比
平均 ITL (ms)	217.14	63.94	-153.20	-70.6%
中位 ITL (ms)	157.45	57.33	-100.12	-63.6%
P95 ITL (ms)	164.60	58.84	-105.76	-64.3%
P99 ITL (ms)	1924.81	74.70	-1850.11	-96.1%

并发级别: 128

服务基准结果

指标	RUN-01	RUN-02	差异	百分比
成功请求数	320	320	0.00	0.0%
失败请求数	0	0	0.00	0.0%
测试持续时间 (s)	1861.45	388.80	-1472.65	-79.1%
总输入 tokens	3276748	3276800	+52.00	+0.0%
总生成 tokens	80952	81920	+968.00	+1.2%
请求吞吐量 (req/s)	0.17	0.82	+0.65	+382.4%
输出 token 吞吐量 (tok/s)	43.49	210.70	+167.21	+384.5%
峰值输出 token 吞吐量 (tok/s)	71.00	1216.00	+1145.00	+1612.7%
峰值并发请求数	132.00	192.00	+60.00	+45.5%
总 token 吞吐量 (tok/s)	1803.81	8638.62	+6834.81	+378.9%

首Token延迟 (TTFT)

指标	RUN-01	RUN-02	差异	百分比
平均 TTFT (ms)	551191.53	125025.53	-426166.00	-77.3%
中位 TTFT (ms)	677657.74	141154.08	-536503.66	-79.2%
P95 TTFT (ms)	697287.77	141224.06	-556063.71	-79.7%
P99 TTFT (ms)	705024.57	141233.23	-563791.34	-80.0%


每Token生成时间 (TPOT)

指标	RUN-01	RUN-02	差异	百分比
平均 TPOT (ms)	217.69	58.43	-159.26	-73.2%
中位 TPOT (ms)	220.15	57.02	-163.13	-74.1%
P95 TPOT (ms)	227.58	57.35	-170.23	-74.8%
P99 TPOT (ms)	233.25	57.35	-175.90	-75.4%

Token间延迟 (ITL)

指标	RUN-01	RUN-02	差异	百分比
平均 ITL (ms)	216.99	58.20	-158.79	-73.2%
中位 ITL (ms)	157.95	57.32	-100.63	-63.7%
P95 ITL (ms)	164.61	73.06	-91.55	-55.6%
P99 ITL (ms)	1925.47	84.96	-1840.51	-95.6%

 RUN-ID对比柱状图



 分析总结

吞吐量对比

请求吞吐量: RUN-02 相比 RUN-01 平均提升 **432.1%**

输出Token吞吐量: RUN-02 相比 RUN-01 平均提升 **428.8%**

延迟对比

TTFT P99: RUN-02 相比 RUN-01 平均改善 **56.9%** (延迟降低)

TPOT P99: RUN-02 相比 RUN-01 平均改善 **54.1%** (延迟降低)

ITL P99: RUN-02 相比 RUN-01 平均改善 **95.9%** (延迟降低)

报告生成时间: 2026-03-31