

MiniMax-M2.5模型在单节点Hygon_BW1000上超长上下文测试对比报告

测试日期： 2026-04-01

对比RUN-ID： 01 vs 02

测试场景

对比同一芯片、同一测试套件下,同一模型优化前后超长上下文场景测试结果比对，分析性能差异。

测试模型

第一轮测试（RUN-01）：MiniMax-M2.5-bf16

第二轮测试（RUN-02）：MiniMax-M2.5-W8A8

vLLM启动配置信息

参数名称	RUN-01	RUN-02
max-model-len	196608	196608
max-num-seqs	10	64
max-num-batched-tokens	8192	N/A
gpu-memory-utilization	0.95	0.9
dp	1	1
tp	8	8
pp	1	1
enable-export-parallel	False	N/A
tool-call-parser	minimax_m2	minimax_m2
reasoning-parser	minimax_m2	N/A
-cc	N/A	{"pass_config": {"fuse_act_quant": false}}

测试概览

项目	配置	备注
数据集	random	
并发数	[1, 2, 4, 8, 10]	
总请求数	[100]	
请求输入上下文长度	[194560]	
请求输出上下文长度	[1024]	
模型	MiniMax-M2.5	
被测芯片	Hygon_BW1000	

主要采集指标：

指标	单位	含义
TTFT	ms	Time To First Token，首 token 延迟
TPOT	ms/token	Time Per Output Token，每 token 生成时间
Throughput	tokens/s	系统总吞吐
QPS	requests/s	请求吞吐
P50/P95/P99 Latency	ms	延迟分位数

各并发级别详细对比

并发级别: 1

服务基准结果

指标	RUN-01	RUN-02	差异	百分比
成功请求数	100	100	0.00	0.0%
失败请求数	0	0	0.00	0.0%
测试持续时间 (s)	8655.55	6683.31	-1972.24	-22.8%
总输入 tokens	19456000	19456000	0.00	0.0%
总生成 tokens	14970	102400	+87430.00	+584.0%
请求吞吐量 (req/s)	0.01	0.01	0.00	0.0%
输出 token 吞吐量 (tok/s)	1.73	15.32	+13.59	+785.5%
峰值输出 token 吞吐量 (tok/s)	8.00	45.00	+37.00	+462.5%
峰值并发请求数	2.00	2.00	0.00	0.0%
总 token 吞吐量 (tok/s)	2249.54	2926.45	+676.91	+30.1%

首Token延迟 (TTFT)

指标	RUN-01	RUN-02	差异	百分比
平均 TTFT (ms)	63442.80	43428.78	-20014.02	-31.5%
中位 TTFT (ms)	64113.52	43851.66	-20261.86	-31.6%
P95 TTFT (ms)	64263.01	44013.66	-20249.35	-31.5%
P99 TTFT (ms)	64339.96	44044.79	-20295.17	-31.5%

每Token生成时间 (TPOT)

指标	RUN-01	RUN-02	差异	百分比
平均 TPOT (ms)	155.46	22.88	-132.58	-85.3%
中位 TPOT (ms)	155.38	22.86	-132.52	-85.3%
P95 TPOT (ms)	157.34	23.00	-134.34	-85.4%
P99 TPOT (ms)	157.59	23.02	-134.57	-85.4%

Token间延迟 (ITL)

指标	RUN-01	RUN-02	差异	百分比
平均 ITL (ms)	155.43	22.89	-132.54	-85.3%
中位 ITL (ms)	155.08	22.87	-132.21	-85.3%
P95 ITL (ms)	161.33	23.99	-137.34	-85.1%
P99 ITL (ms)	171.35	32.91	-138.44	-80.8%

并发级别: 2

服务基准结果

指标	RUN-01	RUN-02	差异	百分比
成功请求数	100	100	0.00	0.0%
失败请求数	0	0	0.00	0.0%
测试持续时间 (s)	8755.03	5910.65	-2844.38	-32.5%
总输入 tokens	19456000	19456000	0.00	0.0%
总生成 tokens	15263	102400	+87137.00	+570.9%
请求吞吐量 (req/s)	0.01	0.02	+0.01	+100.0%
输出 token 吞吐量 (tok/s)	1.74	17.32	+15.58	+895.4%
峰值输出 token 吞吐量 (tok/s)	8.00	70.00	+62.00	+775.0%
峰值并发请求数	3.00	4.00	+1.00	+33.3%
总 token 吞吐量 (tok/s)	2224.01	3309.01	+1085.00	+48.8%

首Token延迟 (TTFT)

指标	RUN-01	RUN-02	差异	百分比
平均 TTFT (ms)	150613.30	66161.43	-84451.87	-56.1%
中位 TTFT (ms)	148787.19	47585.74	-101201.45	-68.0%
P95 TTFT (ms)	166905.14	88211.91	-78693.23	-47.1%
P99 TTFT (ms)	288709.33	88254.14	-200455.19	-69.4%

每Token生成时间 (TPOT)

指标	RUN-01	RUN-02	差异	百分比
平均 TPOT (ms)	155.72	50.88	-104.84	-67.3%
中位 TPOT (ms)	155.74	50.90	-104.84	-67.3%
P95 TPOT (ms)	157.55	71.62	-85.93	-54.5%
P99 TPOT (ms)	158.61	71.98	-86.63	-54.6%

Token间延迟 (ITL)

指标	RUN-01	RUN-02	差异	百分比
平均 ITL (ms)	155.59	50.84	-104.75	-67.3%
中位 ITL (ms)	155.14	30.33	-124.81	-80.4%
P95 ITL (ms)	161.19	32.04	-129.15	-80.1%
P99 ITL (ms)	165.40	57.69	-107.71	-65.1%

并发级别: 4

服务基准结果

指标	RUN-01	RUN-02	差异	百分比
成功请求数	100	100	0.00	0.0%
失败请求数	0	0	0.00	0.0%
测试持续时间 (s)	9218.65	5942.46	-3276.19	-35.5%
总输入 tokens	19456000	19456000	0.00	0.0%
总生成 tokens	16504	102400	+85896.00	+520.5%
请求吞吐量 (req/s)	0.01	0.02	+0.01	+100.0%
输出 token 吞吐量 (tok/s)	1.79	17.23	+15.44	+862.6%
峰值输出 token 吞吐量 (tok/s)	8.00	100.00	+92.00	+1150.0%
峰值并发请求数	5.00	6.00	+1.00	+20.0%
总 token 吞吐量 (tok/s)	2112.29	3291.30	+1179.01	+55.8%

首Token延迟 (TTFT)

指标	RUN-01	RUN-02	差异	百分比
平均 TTFT (ms)	337958.92	105931.79	-232027.13	-68.7%
中位 TTFT (ms)	333410.25	95532.36	-237877.89	-71.3%
P95 TTFT (ms)	408152.45	154928.92	-253223.53	-62.0%
P99 TTFT (ms)	465366.18	164062.99	-301303.19	-64.7%

每Token生成时间 (TPOT)

指标	RUN-01	RUN-02	差异	百分比
平均 TPOT (ms)	155.34	128.77	-26.57	-17.1%
中位 TPOT (ms)	155.21	140.70	-14.51	-9.3%
P95 TPOT (ms)	157.16	185.05	+27.89	+17.7%
P99 TPOT (ms)	157.97	187.07	+29.10	+18.4%

Token间延迟 (ITL)

指标	RUN-01	RUN-02	差异	百分比
平均 ITL (ms)	155.33	128.67	-26.66	-17.2%
中位 ITL (ms)	155.01	43.01	-112.00	-72.3%
P95 ITL (ms)	161.53	51.82	-109.71	-67.9%
P99 ITL (ms)	172.37	3138.27	+2965.90	+1720.7%

并发级别: 8

服务基准结果

指标	RUN-01	RUN-02	差异	百分比
成功请求数	100	100	0.00	0.0%
失败请求数	0	0	0.00	0.0%
测试持续时间 (s)	10080.21	6649.91	-3430.30	-34.0%
总输入 tokens	19456000	19456000	0.00	0.0%
总生成 tokens	18194	102400	+84206.00	+462.8%
请求吞吐量 (req/s)	0.01	0.02	+0.01	+100.0%
输出 token 吞吐量 (tok/s)	1.80	15.40	+13.60	+755.6%
峰值输出 token 吞吐量 (tok/s)	8.00	135.00	+127.00	+1587.5%
峰值并发请求数	9.00	9.00	0.00	0.0%
总 token 吞吐量 (tok/s)	1931.92	2941.15	+1009.23	+52.2%

首Token延迟 (TTFT)

指标	RUN-01	RUN-02	差异	百分比
平均 TTFT (ms)	749261.20	261190.98	-488070.22	-65.1%
中位 TTFT (ms)	753725.89	280961.74	-472764.15	-62.7%
P95 TTFT (ms)	885387.37	307743.39	-577643.98	-65.2%
P99 TTFT (ms)	895508.47	360845.68	-534662.79	-59.7%


每Token生成时间 (TPOT)

指标	RUN-01	RUN-02	差异	百分比
平均 TPOT (ms)	155.65	260.06	+104.41	+67.1%
中位 TPOT (ms)	155.63	268.64	+113.01	+72.6%
P95 TPOT (ms)	157.26	272.02	+114.76	+73.0%
P99 TPOT (ms)	158.33	272.29	+113.96	+72.0%

Token间延迟 (ITL)

指标	RUN-01	RUN-02	差异	百分比
平均 ITL (ms)	155.48	259.82	+104.34	+67.1%
中位 ITL (ms)	155.32	38.62	-116.70	-75.1%
P95 ITL (ms)	162.60	2674.29	+2511.69	+1544.7%
P99 ITL (ms)	176.01	4011.51	+3835.50	+2179.1%

 RUN-ID对比柱状图



 分析总结

吞吐量对比

请求吞吐量: RUN-02 相比 RUN-01 平均提升 **75.0%**

输出Token吞吐量: RUN-02 相比 RUN-01 平均提升 **824.8%**

延迟对比

TTFT P99: RUN-02 相比 RUN-01 平均改善 **56.4%** (延迟降低)

TPOT P99: RUN-02 相比 RUN-01 平均改善 **12.4%** (延迟降低)

ITL P99: RUN-02 相比 RUN-01 平均增加 **938.5%** (延迟增加)

报告生成时间: 2026-04-01